

MinHash & LSH

大规模数据相似度检测的利器



MinHash：集合相似度的签名

核心思想

MinHash通过哈希函数将集合映射到固定大小的签名，使得两个集合的Jaccard相似度可以通过签名快速估计。

Jaccard相似度

$$J(A, B) = |A \cap B| / |A \cup B|$$

即：交集大小 ÷ 并集大小

MinHash算法步骤

- 准备 k 个独立的哈希函数 $h_1, h_2, \dots, h_k$
- 对集合中每个元素应用所有哈希函数
- 对每个哈希函数，取所有元素哈希值的最小值